Studi Ablasi RNN, LSTM, dan GRU dibandingkan ANN untuk Prediksi Trafik Seluler Kota Milan

Shevilla Octaria Fitri
NIM 124400005
Teknik Telekomunikasi, ITERA
Shevilla.124400005@student.itera.ac.id

***Ringkasan*—Peramalan trafik internet per sel membantu operator seluler mengalokasikan sumber daya secara efisien. Laporan ini membandingkan ANN, RNN, LSTM, dan GRU untuk prediksi satu jam ke depan pada data Telecom Italia di kotak Duomo, Milan, melalui studi ablasi: lima faktor wajib (panjang jendela, ukuran hidden, jumlah lapisan, *learning rate*, kelompok fitur) dan dua faktor pilihan (dropout, *patience*), masing-masing dengan tiga seed. Pada konfigurasi acuan, RNN paling akurat (test MAE 229,6 $\pm$ 5,1), disusul GRU (237,2 $\pm$ 9,3), LSTM (273,6 $\pm$ 25,4), dan ANN (309,9 $\pm$ 5,9); seluruhnya mengalahkan baseline naif terbaik (467,6) pada minggu test. *Learning rate* yang terlalu kecil, ukuran hidden, dan (untuk ANN) panjang jendela paling berpengaruh, sedangkan dropout umumnya merugikan. Gabungan nilai terbaik yang dipilih dengan val MAE menurunkan test MAE ANN sebesar 7,6%, LSTM 10,7%, dan GRU 2,5%, tetapi tidak membantu RNN. Di Bandara Linate, RNN dan GRU acuan tetap terbaik (test MAE 7,5), namun konfigurasi terbaik dari Duomo hanya membantu ANN.**

***Index Terms*—prediksi trafik seluler, RNN, LSTM, GRU, studi ablasi**

I. Pendahuluan

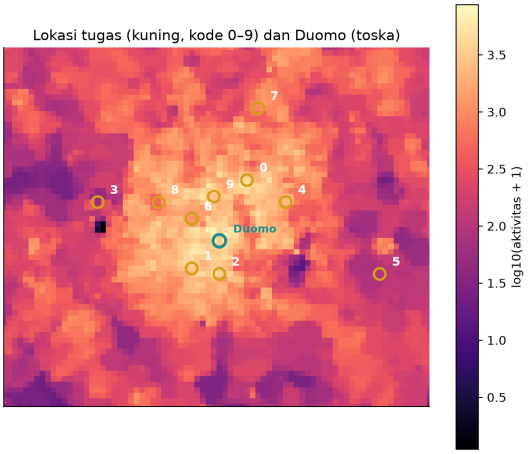
Operator seluler perlu meramal trafik per sel agar kapasitas dan energi dapat dialokasikan sebelum beban memuncak. Model sekuensial seperti RNN, LSTM [1], dan GRU [2] secara alami cocok untuk deret waktu, tetapi data trafik per sel yang tersedia sering kecil dan hasilnya sensitif terhadap pilihan hyperparameter. Studi ablasi, yaitu mengubah satu faktor dalam satu waktu, memisahkan efek tiap faktor dari efek model itu sendiri.

Kontribusi laporan ini: (i) perbandingan terkontrol ANN, RNN, LSTM, dan GRU dengan tiga seed per konfigurasi; (ii) ablasi tujuh faktor beserta hipotesis awal untuk dua faktor pilihan; (iii) uji apakah konfigurasi terbaik di Duomo, yang dipilih hanya dengan data validasi, berlaku di lokasi lain.

II. Data dan Metode

A. Dataset

Data berasal dari Telecom Italia Big Data Challenge [3] dalam bentuk agregat per jam yang disediakan pada materi tugas (lihat juga [4]). Fitur per jam adalah aktivitas internet (*net*, juga menjadi target), panggilan (*call*), SMS, serta jam dan hari dalam bentuk sin–cos. Bagian 0–C memakai kotak Duomo (5060); Bagian D memakai lokasi kelompok, yaitu kode 5, Bandara Linate (kotak 4489), yang berupa area dengan trafik rendah. Gambar 1 menunjukkan letak lokasi-lokasi tugas.



Gambar 1. Rata-rata aktivitas internet per kotak di Milan. Lingkaran kuning: lokasi tugas (kode 0–9); lingkaran toska: Duomo.

B. Pembagian Data dan Praproses

Data dibagi berdasarkan waktu: *train* 11 Nov–8 Des 2013, validasi 9–15 Des, test 16–22 Des, dan minggu Natal 23–29 Des; minggu 4–10 Nov hanya menjadi konteks jendela. Pembagian tidak diacak karena data deret waktu yang diacak membocorkan masa depan ke masa lalu dan membuat metrik terlalu optimistis. Standarisasi memakai rata-rata dan simpangan baku dari data sebelum minggu validasi. Satu sampel berupa jendela W jam terakhir untuk memprediksi *net* jam berikutnya (horizon 1 jam).

C. Model dan Konfigurasi Acuan

ANN meratakan jendela lalu melewatkannya ke lapisan tersembunyi ReLU. RNN, LSTM, dan GRU menumpuk lapisan rekuren dan memakai *hidden state* jam terakhir untuk lapisan keluaran. Semua model dilatih dengan PyTorch [5]. Konfigurasi acuan ada pada Tabel I.

D. Protokol Ablasi dan Evaluasi

Setiap eksperimen mengubah satu faktor dari acuan: panjang jendela $W \in \{6, 12, 24, 48, 168\}$ (A1), ukuran hidden $\{16, 32, 64, 128\}$ (A2), jumlah lapisan $\{1, 2, 3\}$ (A3), *learning rate* $\{10^{-4}, 10^{-3}, 10^{-2}\}$ (A4), dan kelompok fitur (A5); faktor pilihan kami adalah dropout $\{0; 0{,}2; 0{,}5\}$ (B2) dan *patience* $\{10, 30, 60\}$ (B5). Tiap konfigurasi dilatih dengan seed 0, 1,

Tabel I
KONFIGURASI ACUAN

Hyperparameter	Nilai acuan
Panjang jendela W	24 jam
Horizon	1 jam
Ukuran hidden	ANN 32, RNN 68, LSTM 33, GRU 38
Jumlah lapisan	ANN 2, rekuren 1
Fitur	net, call, sms, jam, hari (7)
Optimizer, *learning rate*	Adam, 10^{-3}
Batch size, dropout	64, 0
Loss	MSE
Early stopping	*patience* 30, maks. 300 epoch

Tabel II
MAE DI DUOMO (HORIZON 1 JAM): BASELINE NAIF DAN MODEL ACUAN (RATA-RATA ± SIMPANGAN BAKU, 3 SEED).

	Val	Test	Natal
Naif: nilai terakhir	662,6	600,9	431,2
Naif: kemarin	595,3	552,2	921,5
Naif: minggu lalu	492,8	467,6	1426,2
ANN	$248{,}9 \pm 8{,}9$	$309{,}9 \pm 5{,}9$	$680{,}1 \pm 52{,}0$
RNN	$206{,}1 \pm 7{,}4$	$\mathbf{229{,}6 \pm 5{,}1}$	$\mathbf{421{,}2 \pm 2{,}4}$
LSTM	$230{,}5 \pm 12{,}2$	$273{,}6 \pm 25{,}4$	$586{,}0 \pm 56{,}8$
GRU	$207{,}5 \pm 3{,}8$	$237{,}2 \pm 9{,}3$	$468{,}2 \pm 21{,}8$

dan 2 dan dilaporkan sebagai rata-rata ± simpangan baku. Pelatihan berhenti dini pada val MSE terbaik. Metrik dihitung pada skala asli: MAE (utama), MAPE, dan RMSE (RMSE tercatat di `ablasi.csv`). Konfigurasi terbaik dipilih *hanya* dengan val MAE; minggu test dan Natal dipakai sekali untuk pelaporan akhir. Eksperimen berjalan di ASUS Vivobook dengan total waktu training 108.2 menit .

III. HASIL

A. Baseline Naif dan Acuan

Tabel II membandingkan model acuan dengan tiga tebakan tanpa belajar (nilai terakhir, kemarin, minggu lalu). Pada minggu validasi dan test, keempat model mengalahkan baseline terbaik (minggu lalu: 492,8 dan 467,6). Urutan model pada test adalah RNN, GRU, LSTM, ANN, tetapi selisih RNN dan GRU lebih kecil daripada satu simpangan baku GRU. Pada minggu Natal, hanya RNN (421,2) yang sedikit melampaui baseline nilai terakhir (431,2); ANN, LSTM, dan GRU lebih buruk.

B. Ablasi Wajib

Gambar 2 dan 3 memuat MAE validasi (kiri) dan test (kanan) terhadap nilai tiap faktor; Tabel III merangkum nilai terbaik berdasarkan val MAE.

A1, panjang jendela. Val MAE ANN naik monoton dari 211,5 (W=6) menjadi 298,2 (W=168), sedangkan jumlah parameternya naik dari 2.465 menjadi 38.753. Parameter RNN tetap 5.305 untuk semua W dan val MAE-nya hanya bergerak antara 200,1 dan 215,5 (terbaik di W=48). LSTM terbaik di W=6 (227,1), GRU di W=48 (206,7).

A2, ukuran hidden. Hidden yang lebih besar menurunkan val MAE ANN (257,6 menjadi 233,8), LSTM (244,3 menjadi 207,1), dan GRU (216,8 menjadi 188,7); RNN mendatar sejak 64 (207,2 vs. 207,7 untuk 128). GRU dengan hidden 128 menghasilkan val MAE terendah di seluruh ablasi (188,7).

Tabel III
NILAI TERBAIK TIAP FAKTOR MENURUT VAL MAE: NILAI (VAL MAE RATA-RATA). W DALAM JAM; HID. = HIDDEN; LAP. = LAPISAN; PAT. = *patience*; N+W = NET+WAKTU.

Faktor	ANN	RNN	LSTM	GRU
A1 W	6 (211,5)	48 (200,1)	6 (227,1)	48 (206,7)
A2 hid.	128 (233,8)	64 (207,2)	128 (207,1)	128 (188,7)
A3 lap.	1 (240,9)	1 (206,1)	1 (230,5)	2 (203,3)
A4 *lr*	10^{-3} (248,9)	10^{-3} (206,1)	10^{-2} (215,9)	10^{-3} (207,5)
A5 fitur	n+w (246,0)	semua (206,1)	semua (230,5)	semua (207,5)
B2 drop.	0 (248,9)	0 (206,1)	0 (230,5)	0,2 (203,9)
B5 *pat.*	60 (241,8)	30 (206,1)	60 (223,3)	60 (205,6)

A3, jumlah lapisan. Lapisan tambahan umumnya tidak membantu. LSTM tiga lapis paling buruk (val 338,9; test 412,6), RNN tiga lapis 225,1, sedangkan GRU dua lapis hanya sedikit lebih baik di val (203,3 vs. 207,5) dan tidak di test (239,2 vs. 237,2).

A4, *learning rate*. Dengan 10^{-4} seluruh model berhenti di batas 300 epoch dan val MAE memburuk (misalnya LSTM 399,4 dan GRU 398,4), tanda belum konvergen. Dengan 10^{-2}, training berhenti jauh lebih cepat (rata-rata 62–68 epoch dibanding 106–194), dan efeknya bergantung model: LSTM membaik (val 215,9; test 225,8), GRU membaik di test (215,7) tetapi tidak di val (208,2), sedangkan ANN dan RNN memburuk di val.

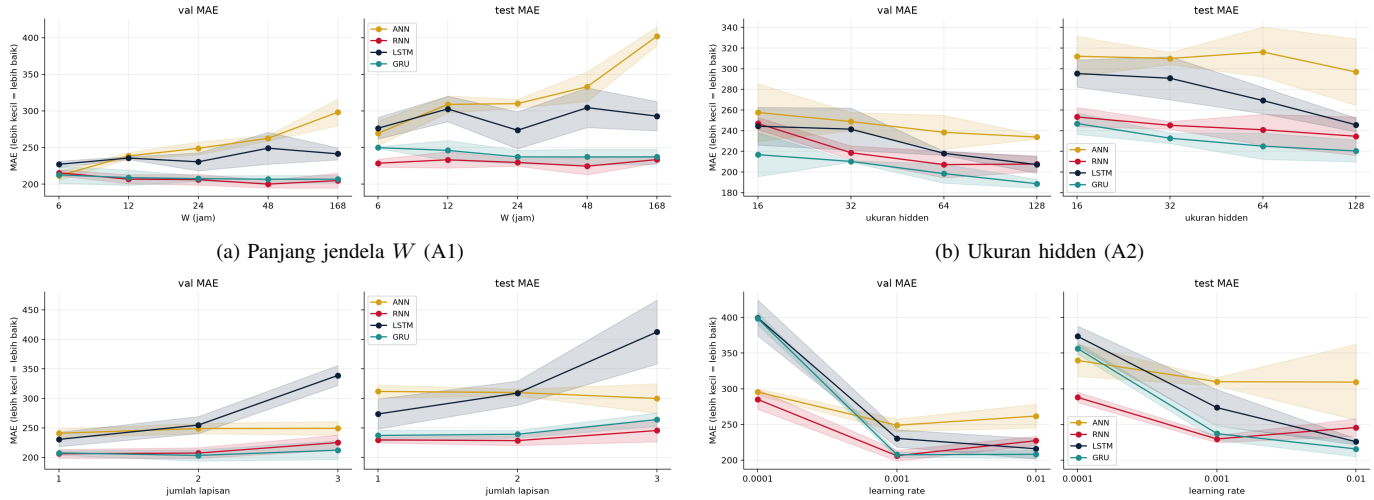
A5, fitur. Memakai *net* saja terburuk untuk model rekuren (val RNN 245,2; LSTM 266,2; GRU 264,6). Menambah jam dan hari atau call dan SMS sama-sama membantu, dan seluruh fitur terbaik untuk RNN, LSTM, dan GRU (206,1; 230,5; 207,5). ANN sedikit lebih baik dengan *net*+waktu (246,0 vs. 248,9), selisih yang masih dalam kisaran simpangan baku.

C. Ablasi Pilihan

Kami memilih dropout (B2), karena data *train* hanya sekitar 672 sampel sehingga overfit mungkin terjadi, dan *patience* (B5), karena menentukan kapan training berhenti.

B2, hipotesis. (i) ANN paling diuntungkan dropout 0,2; (ii) dropout 0,5 merugikan semua model; (iii) efek pada model rekuren kecil; (iv) simpangan baku antar seed naik pada 0,5. **Hasil:** (i) *ditolak*: val MAE ANN naik dari 248,9 menjadi 274,4 (0,2) dan 377,7 (0,5). (ii) *terbukti*: pada 0,5 val MAE semua model memburuk (RNN 254,8; LSTM 247,4; GRU 259,5). (iii) *sebagian*: LSTM nyaris tidak berubah (230,5 menjadi 231,8) dan GRU sedikit membaik pada 0,2 (203,9), tetapi RNN memburuk cukup besar (206,1 menjadi 239,5). (iv) *sebagian*: naik pada ANN, RNN, GRU, tetapi turun pada LSTM.

B5, hipotesis. (i) *patience* 10 berhenti terlalu dini sehingga lebih buruk dengan epoch terendah; (ii) 30 dan 60 hampir sama. **Hasil:** (i) *terbukti*: *patience* 10 memberi val MAE terburuk untuk semua model (ANN 271,8; RNN 220,2; LSTM 250,1; GRU 218,1) dengan jumlah epoch terkecil. (ii) *sebagian*: RNN (206,1 vs. 206,6) dan GRU (207,5 vs. 205,6) hampir sama,



(a) Panjang jendela W (A1)

(b) Ukuran hidden (A2)

(c) Jumlah lapisan (A3)

(d) *Learning rate* (A4)

Gambar 2. Pengaruh faktor wajib A1–A4 terhadap MAE validasi (kiri) dan test (kanan) di Duomo; satu garis per model, area = ± 1 simpangan baku antar seed.

Tabel IV
KONFIGURASI TERBAIK PER MODEL (N+W = NET+WAKTU).

Model	W	hidden	lapisan	*lr*	fitur	dropout	*patience*
ANN	6	128	1	10^{-3}	n+w	0	60
RNN	48	64	1	10^{-3}	semua	0	30
LSTM	6	128	1	10^{-2}	semua	0	60
GRU	48	128	2	10^{-3}	semua	0,2	60

tetapi ANN (248,9 menjadi 241,8) dan LSTM (230,5 menjadi 223,3) sedikit membaik pada 60, dengan konsekuensi epoch rata-rata ANN naik dari 106 menjadi 172.

D. Konfigurasi Terbaik

Konfigurasi terbaik tiap model (Tabel IV) dibentuk dengan menggabungkan nilai terbaik tiap faktor menurut val MAE (Tabel III). Hasilnya pada Tabel V dan Gambar 4. Pada ANN, LSTM, dan GRU, test MAE turun masing-masing 7,6%, 10,7%, dan 2,5%. Pada RNN gabungan justru lebih buruk dari acuan, bahkan di val (212,7 vs. 206,1; simpangan baku 16,1 karena satu seed buruk). Kami melaporkannya apa adanya dan tidak mencoba kombinasi tambahan. Perbaikan di test juga tidak selalu terbawa ke Natal: GRU memburuk dari 468,2 menjadi 536,1, sedangkan ANN (680,1 menjadi 580,7) dan LSTM (586,0 menjadi 498,4) membaik. Pada GRU, hidden 128 saja memberi val MAE 188,7, tetapi gabungan seluruh faktor hanya 206,7, tanda bahwa faktor saling memengaruhi.

E. Uji Generalisasi

Tabel VI memuat hasil di Bandara Linate dengan konfigurasi acuan dan terbaik dari Duomo tanpa diubah. Skala error jauh lebih kecil (MAE sekitar 7–9) karena trafik di sana rendah. RNN dan GRU acuan tetap terbaik di test (7,5), sama seperti di Duomo, dan semua model mengalahkan baseline test terbaik (nilai terakhir, 10,1). Namun konfigurasi terbaik dari Duomo hanya membantu ANN (test 8,8 menjadi 7,7); pada RNN (7,5

Tabel V
MAE DI DUOMO: ACUAN VS. TERBAIK (RATA-RATA $\pm$ SIMPANGAN BAKU, 3 SEED).

Model	Konfig.	Val	Test	Natal
ANN	acuan	$248{,}9 \pm 8{,}9$	$309{,}9 \pm 5{,}9$	$680{,}1 \pm 52{,}0$
	terbaik	$220{,}9 \pm 1{,}9$	$286{,}2 \pm 5{,}9$	$580{,}7 \pm 28{,}0$
RNN	acuan	$206{,}1 \pm 7{,}4$	$229{,}6 \pm 5{,}1$	$421{,}2 \pm 2{,}4$
	terbaik	$212{,}7 \pm 16{,}1$	$247{,}7 \pm 21{,}6$	$433{,}0 \pm 53{,}8$
LSTM	acuan	$230{,}5 \pm 12{,}2$	$273{,}6 \pm 25{,}4$	$586{,}0 \pm 56{,}8$
	terbaik	$220{,}6 \pm 15{,}0$	$244{,}2 \pm 18{,}2$	$498{,}4 \pm 8{,}9$
GRU	acuan	$207{,}5 \pm 3{,}8$	$237{,}2 \pm 9{,}3$	$468{,}2 \pm 21{,}8$
	terbaik	$206{,}7 \pm 9{,}5$	$231{,}2 \pm 10{,}5$	$536{,}1 \pm 44{,}9$

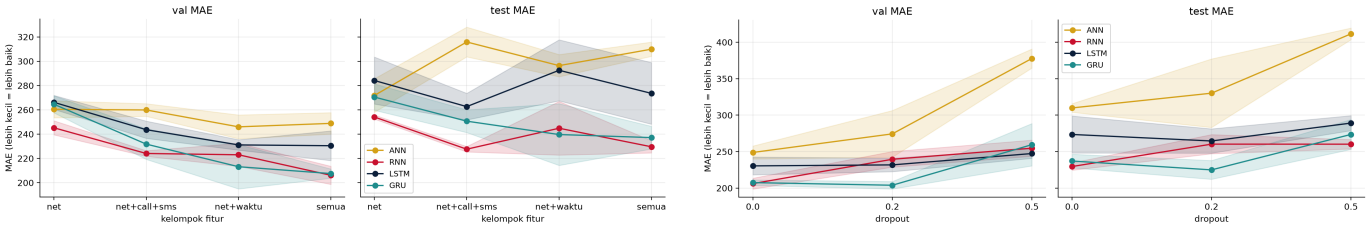
Tabel VI
MAE DI BANDARA LINATE (KODE 5): BASELINE NAIF, ACUAN, DAN TERBAIK DARI DUOMO (RATA-RATA $\pm$ SIMPANGAN BAKU, 3 SEED).

Model	Konfig.	Val	Test	Natal
Naif: nilai terakhir		10,4	10,1	7,1
Naif: kemarin		16,7	20,4	15,2
Naif: minggu lalu		13,0	15,4	28,5
ANN	acuan	$8{,}7 \pm 0{,}0$	$8{,}8 \pm 0{,}7$	$14{,}4 \pm 0{,}5$
	terbaik	$8{,}7 \pm 0{,}1$	$7{,}7 \pm 0{,}1$	$13{,}0 \pm 1{,}2$
RNN	acuan	$8{,}5 \pm 0{,}1$	$7{,}5 \pm 0{,}1$	$10{,}8 \pm 0{,}1$
	terbaik	$8{,}8 \pm 0{,}1$	$7{,}9 \pm 0{,}3$	$11{,}0 \pm 1{,}0$
LSTM	acuan	$9{,}3 \pm 0{,}1$	$8{,}2 \pm 0{,}2$	$12{,}8 \pm 0{,}8$
	terbaik	$8{,}2 \pm 0{,}2$	$8{,}5 \pm 0{,}3$	$13{,}2 \pm 0{,}5$
GRU	acuan	$9{,}2 \pm 0{,}1$	$7{,}5 \pm 0{,}2$	$11{,}4 \pm 0{,}9$
	terbaik	$8{,}7 \pm 0{,}1$	$7{,}7 \pm 0{,}2$	$12{,}3 \pm 0{,}3$

menjadi 7,9) dan LSTM (8,2 menjadi 8,5) test MAE justru naik, meskipun val LSTM membaik (9,3 menjadi 8,2). Pada minggu Natal, baseline nilai terakhir (7,1) mengalahkan semua model (10,8–14,4), seperti halnya di Duomo.

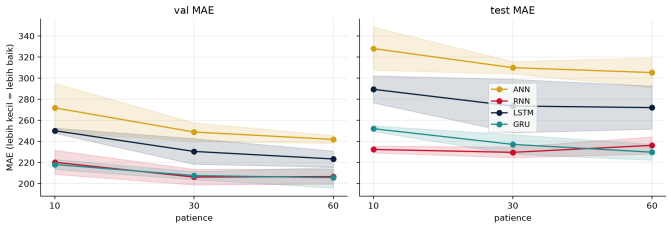
IV. PEMBAHASAN

Faktor yang paling berpengaruh. Efek terbesar datang dari *learning rate* yang terlalu kecil (semua model mentok



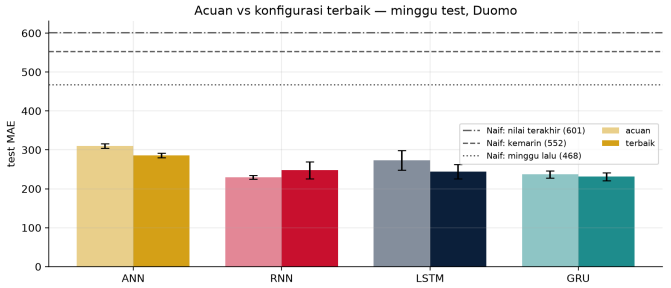
(a) Kelompok fitur (A5)

(b) Dropout (B2)



(c) *Patience* (B5)

Gambar 3. Pengaruh kelompok fitur (A5), dropout (B2), dan *patience* (B5) terhadap MAE validasi (kiri) dan test (kanan) di Duomo.



Gambar 4. Test MAE di Duomo: konfigurasi acuan vs. terbaik, dengan garis baseline naif.

di 300 epoch dan memburuk tajam), ukuran hidden (terutama GRU dan LSTM), dan, khusus ANN, panjang jendela. Penjelasan untuk ANN terlihat dari jumlah parameter: masukan yang diratakan membuat parameter tumbuh dari 2.465 ke 38.753 saat W naik dari 6 ke 168, padahal *train* hanya sekitar 672 sampel, sehingga overfit sangat mungkin terjadi (dugaan kami; tidak diuji langsung). Model rekuren berbagi bobot sepanjang waktu, sehingga parameternya tetap dan hasilnya jauh lebih stabil terhadap W. Faktor yang efeknya kecil atau tidak konsisten: jumlah lapisan (kecuali LSTM tiga lapis yang jelas merugikan) dan *patience* di atas 30.

Dropout. Dropout umumnya merugikan, yang menurut dugaan kami karena model sudah kecil dan data pendek sehingga masalah utamanya lebih dekat ke *underfitting* daripada overfit; hal ini belum kami uji lebih lanjut. Hipotesis awal bahwa ANN paling diuntungkan ternyata salah.

Model versus seed. Selisih RNN dan GRU di test (229,6 vs. 237,2) lebih kecil daripada simpangan baku GRU, sehingga dengan tiga seed keduanya tidak dapat dibedakan secara meyakinkan; yang jelas adalah keduanya lebih baik dari LSTM dan ANN. LSTM juga paling bervariasi antar seed (simpangan baku test 25,4 vs. 5,1 pada RNN). Tidak ada satu model dan konfigurasi yang menang di semua minggu: pada Natal, hanya RNN acuan yang menyaingi baseline nilai terakhir, dan di Duomo maupun Linate baseline itu sulit dikalahkan pada minggu tersebut. Dugaan kami, pola trafik Natal berbeda dari minggu-minggu *train* yang semuanya hari kerja biasa.

Keterbatasan. Studi ini memakai satu kota, empat minggu data *train*, satu pembagian waktu, dan tiga seed; faktor diuji satu per satu sehingga interaksi tidak terpetakan penuh (kasus GRU hidden 128 menunjukkan interaksi itu nyata); dan konfigurasi terbaik Duomo tidak otomatis berlaku di Linate.

V. Kesimpulan

Pada prediksi trafik per jam di Duomo, RNN dan GRU paling akurat dan paling stabil terhadap panjang jendela (test MAE acuan 229,6 dan 237,2), sedangkan ANN paling sensitif terhadap jendela panjang dan dropout. *Learning rate* yang terlalu kecil dan ukuran hidden adalah faktor yang paling menentukan; dropout dan lapisan tambahan umumnya tidak membantu. Menggabungkan nilai terbaik menurunkan test MAE ANN, LSTM, dan GRU (7,6%, 10,7%, 2,5%) tetapi tidak RNN, dan hasilnya di Linate hanya berlaku untuk ANN. Karena itu, konfigurasi sebaiknya dipilih ulang di setiap lokasi.

Kontribusi Anggota

Kelompok ini beranggotakan satu orang, Shevilla Octaria Fitri (NIM 124400005), yang mengerjakan seluruh eksperimen, analisis, dan penulisan laporan.

Pernyataan Penggunaan AI

Claude (Anthropic) digunakan untuk membantu menyiapkan lingkungan kerja (Jupyter lab, Git, GitHub), memeriksa notebook, dan menyusun draf serta merapikan bahasa laporan ini. Seluruh angka berasal dari run kelompok kami sendiri dan dapat ditelusuri ke `hasil/ablasi.csv`.

Kode dan Data

Kode, notebook beserta output, dan seluruh hasil run tersedia di https://github.com/shevilla124400005-stack/dlw-tugas-ra-124400005.

PUSTAKA

[1] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

[2] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, "Learning phrase representations using RNN encoder–decoder for statistical machine translation," in *Proc. EMNLP*, 2014, pp. 1724–1734.

[3] G. Barlacchi *et al.*, "A multi-source dataset of urban life in the city of Milan and the Province of Trentino," *Scientific Data*, vol. 2, p. 150055, 2015.

[4] C. Zhang, S. Dang, B. Shihada, and M.-S. Alouini, "Dual attention-based federated learning for wireless traffic prediction," in *Proc. IEEE INFOCOM*, 2021, pp. 1–10.

[5] A. Paszke *et al.*, "PyTorch: An imperative style, high-performance deep learning library," in *Advances in Neural Information Processing Systems 32*, 2019, pp. 8024–8035.